

DÉPARTEMENT DE SCIENCES ET INGÉNIERIE

PROJET DE COCOMA

Multi-Agent Reinforcement Learning

Auteurs:
Jawher JRIBY 3702809
Mélanie DELLUC 21104033

Janvier 2026

Sommaire

1 Introduction **1**

2 Principe général **1**

3 Méthodologie **2**

4 Résultats **2**

4.1 Qualité de la politique apprise 2

4.2 Communication inter-agents 3

5 Conclusion **4**

1 Introduction

Le Multi-Agent Reinforcement Learning regroupe des méthodes d'apprentissage par renforcement appliquées à des environnements où plusieurs agents interagissent simultanément. Ces approches MARL sont particulièrement utiles lorsque plusieurs entités doivent notamment coopérer pour atteindre un objectif commun.

Dans ce projet, nous avons, dans un premier temps, implémenté une méthode MARL naïve, puis ajouté de la communication entre les divers agents. Nous les avons testées sur l'environnement WaterWorld de la librairie PettingZoo. Cet environnement représente une simulation d'agents dont l'objectif est de consommer des ressources bénéfiques (food), tout en évitant les éléments néfastes (poison). Certaines des ressources bénéfiques ont besoin d'une action coordonnée de plusieurs agents pour être consommées, ce qui explique l'aspect coopératif, et ainsi la nécessité de communication entre agents, étant donnée que ceux-ci n'ont qu'une vision partielle de l'environnement.

2 Principe général

Dans un premier temps, nous avons implémenté une version naïve de la méthode Proximal Policy Optimization (PPO) dans l'environnement WaterWorld pour un seul agent. Une fois qu'elle nous semblait cohérente avec le résultat attendu, nous l'avons élargi à l'ensemble des agents de notre système. Ainsi, plusieurs agents s'entrainent simultanément à l'aide d'une politique partagée mais sans communication explicite entre eux. Ensuite, afin d'intégrer de la communication entre agents, nous leur faisons exécuter un entraînement basé sur la méthode Centralized Training / Decentralized Execution (CTDE). Donc pendant l'apprentissage, un critique centralisé a accès aux observations de l'intégralité des agents, mais au moment de l'exécution, chaque agent agit uniquement avec ses informations locales et les messages reçus. Cette stratégie de communication devrait nous permettre d'obtenir de meilleurs résultats que pour l'approche naïve car ainsi, les agents peuvent se coordonner au travers de messages pour récupérer de manière plus optimale les ressources bénéfiques et ainsi maximiser leur gain total.

Nous avons choisi l'algorithme PPO (Proximal Policy Optimization) car il est particulièrement adapté aux environnements complexes à actions continues, comme Waterworld, où les agents évoluent librement dans l'espace. PPO offre un apprentissage stable, en limitant les mises à jour trop brutales de la politique, ce qui est essentiel dans un contexte multi-agent où les comportements des agents sont interdépendants. L'algorithme s'intègre naturellement dans le cadre du Centralized Training / Decentralized Execution (CTDE) : durant l'entraînement, un critic centralisé exploite des informations globales pour faciliter l'apprentissage, tandis qu'à l'exécution chaque agent agit de manière décentralisée. La politique repose sur un réseau récurrent de type GRU, permettant aux agents de conserver une mémoire des observations passées et de mieux gérer la partial observability de l'environnement. Enfin, un mécanisme de communication différentiable est intégré à la politique :

chaque agent échange des messages appris avec ses voisins, ce qui améliore la coordination entre agents pour accomplir des tâches coopératives

3 Méthodologie

À chaque itération, plusieurs environnements sont exécutés en parallèle afin de collecter des trajectoires. Les observations sont normalisées et les avantages sont calculés à l'aide de la méthode Generalized Advantage Estimation (GAE), permettant de stabiliser l'apprentissage. La politique est ensuite mise à jour à l'aide de l'objectif PPO clippé, avec un terme d'entropie favorisant l'exploration et un arrêt anticipé basé sur la divergence KL.

L'évaluation est réalisée régulièrement pendant l'entraînement. La politique est alors exécutée de manière déterministe, sans apprentissage, sur plusieurs épisodes indépendants. Les performances sont mesurées à partir de la récompense moyenne par épisode, ce qui permet de suivre la progression de l'apprentissage et de comparer les différentes approches.

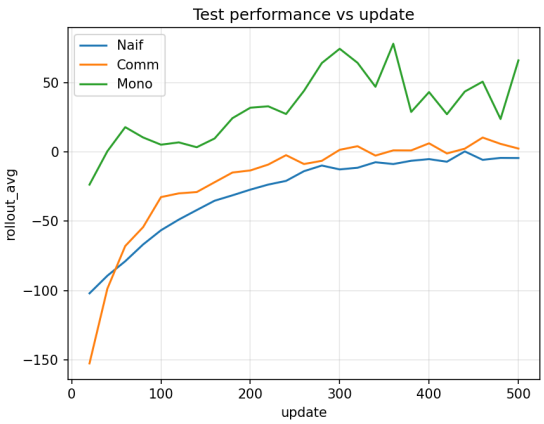
La même méthodologie est utilisée pour le cas mono-agent, multi-agents sans communication et multi-agents avec communication, afin de garantir une comparaison équitable entre les différentes configurations.

Dans le cas du MARL naïf mono-agent, les ressources consommables peuvent être consommées par un agent, il n'est donc pas nécessaire d'être à plusieurs agents pour les gagner. Ainsi, certains de nos résultats par la suite seront élevés dans le cas du mono-agent naïf, par le biais de cette contrainte en moins, n'impliquant pas la nécessité d'un comportement coopératif entre agents. Cependant, pour le cas naïf multi-agents et avec communication, cette contrainte est bien respectée.

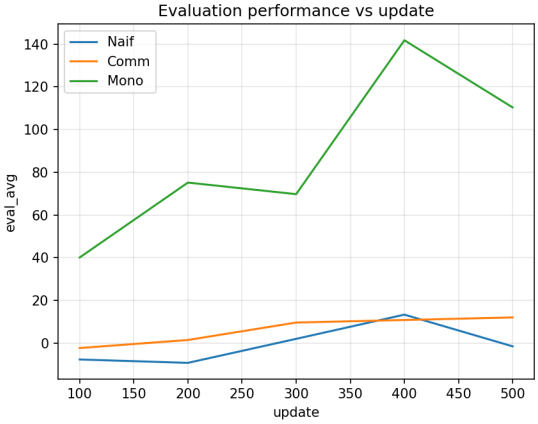
4 Résultats

4.1 Qualité de la politique apprise

Nous pouvons observer sur le graphique de la phase d'entraînement que les performances du MARL avec communication augmentent très rapidement, traduisant une vitesse de convergence élevée, avant d'atteindre une phase de stabilisation. Tandis que le MARL naïf semble avoir plus de difficultés à améliorer ses performances de manière efficace mais atteint tout de même une convergence légèrement inférieure à celle du MARL avec communication. Cette observation s'explique par le fait que la communication facilite la coordination entre agents et réduit la non-stationnarité de l'environnement perçue par chacun, conduisant à une convergence plus rapide et plus stable de la politique apprise. Ainsi, dans le cas du MARL naïf, l'absence de communication rend l'environnement plus difficile à appréhender, ce qui ralentit l'amélioration des performances et conduit à un apprentissage moins efficace.



(a) Performance moyenne en fonction des updates (entraînement).



(b) Performance moyenne en fonction des updates (évaluation).

Figure 1: Analyse de l'évolution des performances de la politique en entraînement et en évaluation.

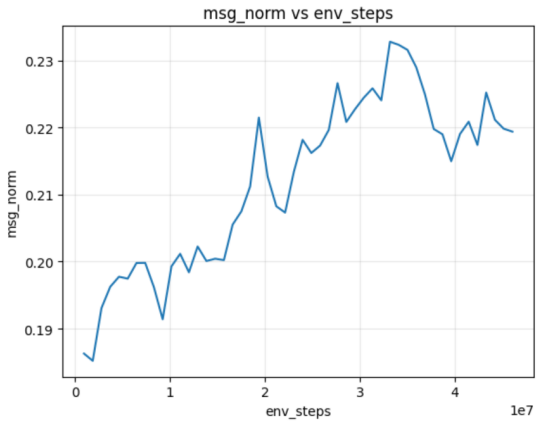
Dans le cas de l'évaluation, nous constatons une qualité de politique apprise assez similaire que celle pour la phase de test. En effet, on observe que le MARL avec communication augmente sa récompense moyenne, même si ce n'est pas aussi rapide que pour le test. Cette augmentation de performance confirme que les améliorations observées en entraînement se traduisent par une meilleure généralisation. Le MARL naïf obtient cependant des résultats toujours inférieurs au MARL avec communication, pour les mêmes raisons que citées précédemment.

Cependant, nous pouvons distinguer un pic supérieur à la performance vers les 400 updates, puis une baisse immédiate des performances pour le MARL naïf. Ce comportement peut être interprété comme le résultat de fluctuations stochastiques ou d'une variance élevée dans l'apprentissage, conduisant à des améliorations ponctuelles non durables. Tandis que le MARL avec communication ne présente pas ce type de variation brutale, ce qui peut suggérer une plus grande robustesse de la politique apprise face aux aléas de l'environnement.

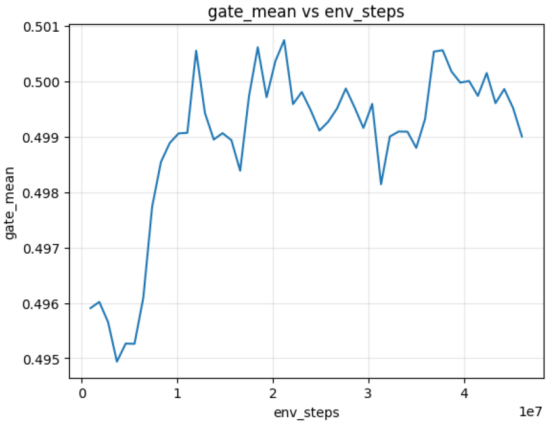
4.2 Communication inter-agents

Le graphique représentant l'évolution de la norme moyenne des messages échangés montre que l'amplitude des messages augmente rapidement durant les premières phases d'apprentissage, puis se stabilise progressivement. Ce comportement indique que la communication entre agents est assez active, les agents communiquent beaucoup avec leurs voisins afin de coordonner leurs actions. Cette hausse de l'usage de communication peut s'expliquer par le fait que les agents apprennent qu'échanger des messages leur permet d'améliorer leurs décisions et de maximiser leur gain collectif.

Le second graphique montre que la valeur moyenne du gate reste relativement stable autour de 0.5 tout au long de l'apprentissage. Cette tendance suggère que les



(a) Norme moyenne des messages échangés.



(b) Valeur moyenne du mécanisme de gate.

Figure 2: Analyse de l'utilisation du canal de communication.

agents accordent une importance significative aux messages reçus, sans pour autant s'y reposer exclusivement. Cela démontre que les agents décident et agissent selon leur politique, mais également selon ce que les autres agents leur communiquent.

5 Conclusion

D'après nos résultats, nous pouvons dire que l'approche naïve permet un apprentissage fonctionnel, mais celle-ci n'est pas optimale en terme de qualité de solution. Tandis que l'approche avec communication entre agents améliore davantage la politique d'apprentissage.

Ces résultats nous prouvent que l'ajout de communication s'avère très utile, et même parfois indispensable dans les cas d'environnements multi-agents complexes. La communication permet de transmettre des informations aux autres agents et ainsi de mieux se coordonner pour une consommation de ressources optimale, tout en évitant les éléments négatifs de l'environnement.